



数字图像处理 Project 展示

CGI-HRDC 2023 - Hypertensive Retinopathy Diagnosis Challenge

张天瑞 张昊然 王瑶瑶
2023 年 12 月 21 日



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

展示内容



- 1 项目简介
- 2 相关工作
- 3 研究内容与方法
- 4 实验结果与分析
- 5 特色与创新

第 1 节

项目简介



项目意义与依据

- 高血压 → 54% 的中风发生率和 47% 的冠心病事故
- 早发现，早治疗
- 传统技术的限制



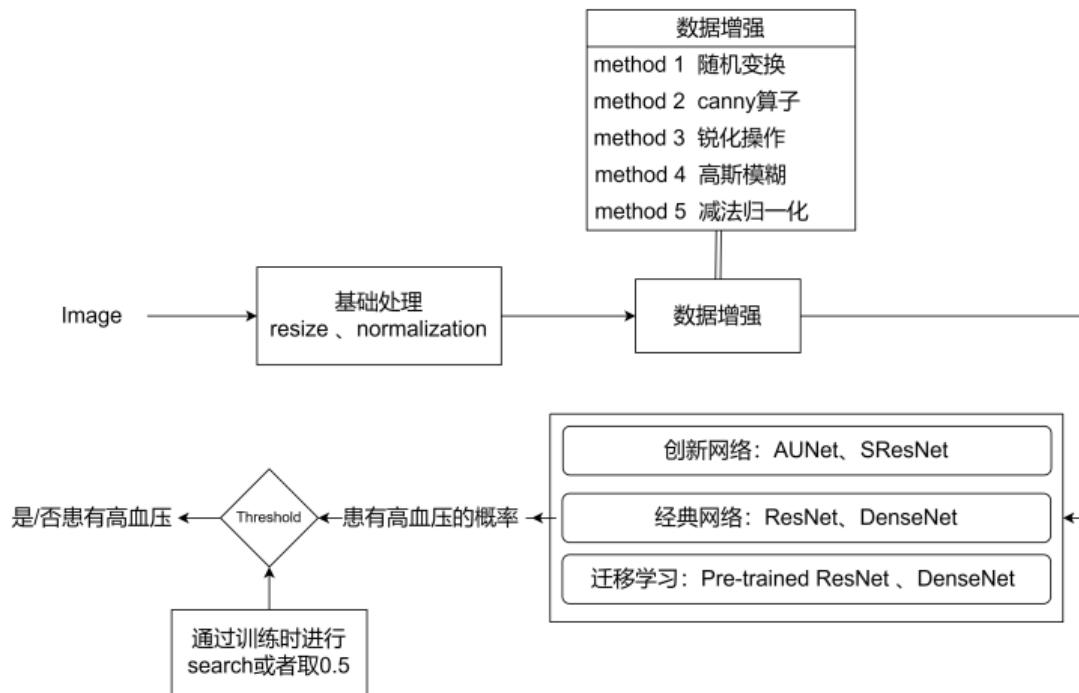
任务要求



CGI-HRDC 2023 Task 1

- 提供 712 张视网膜图片（正/负 = 1 : 1）
- 训练分类模型
- 对有/无高血压视网膜病变进行分类

本方法/系统框架



第 2 节

相关工作



相关工作

文献的搜集与整理



PNN 筛查

- 盒计数
- 不变矩
- 平滑参数与准确性

血管分割网络

少量可训练参数得到满意分割，原始图像无需处理直接提供给网络进行训练与调试

卷积多任务架构

- 监督学习和弱监督学习
- 原始图像和预处理图像的颜色一致性

自动化 HR 检测和分级

- 提取血管和视盘
- 动静脉分类
- 计算动静脉宽度比

深度残差学习

结合经过训练的特征层与 CNN

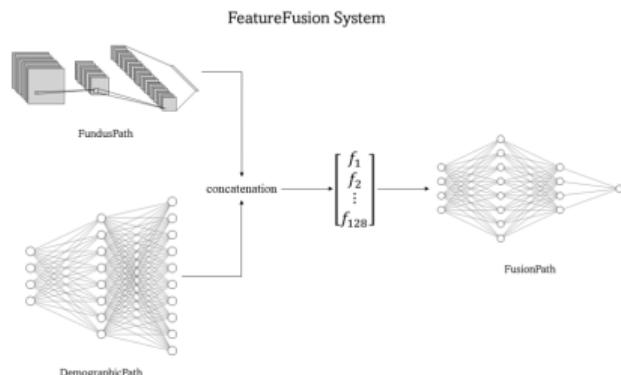
...

...

相关工作

HyMNet

HyMNet 采用多模态的思想，综合了图像输入和年龄、性别特征的输入。



图：HyMNet 网络结构

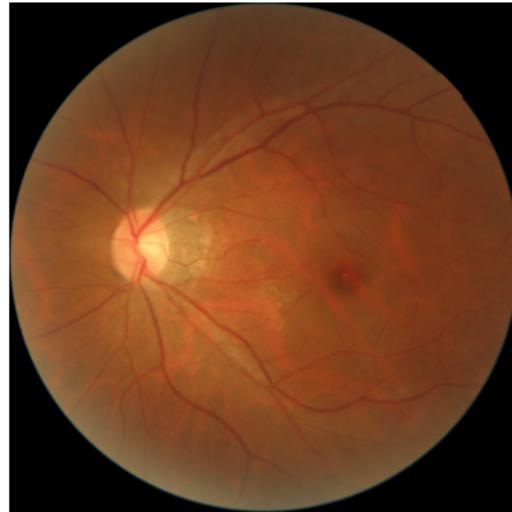
第 3 节

项目内容与方法

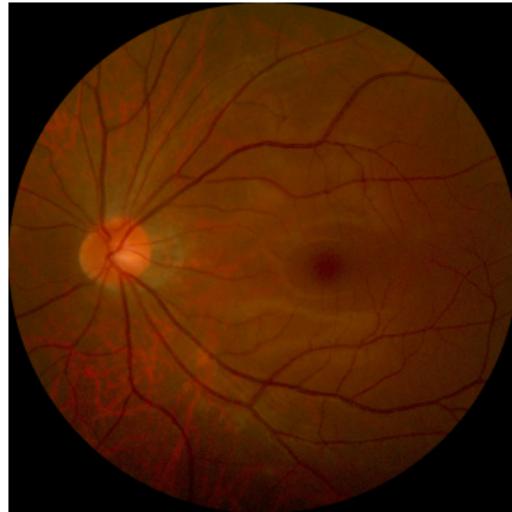


数据集介绍

我们的数据集为 712 张 800*800 大小的视网膜图像，每张图像有对应的标签表示其有无高血压。我们按照大约 8: 1 的比例划分训练集和测试集。



图：正常人视网膜图像



图：患者视网膜图像



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

数据预处理

影响分类结果的关键因素



数据划分 将给定的数据集大约按照 8:1 随机划分成训练集和验证集

- 训练集用于训练模型，实际训练时会随机打乱顺序
- 验证集用于评估模型，在整个训练过程中不会变化

基础处理

- resize, 归一化, 维度重排, 数据类型转换...

数据增强 图片随机翻转, 随机旋转, 高斯噪声...

- 效果有好有坏
- 数据增强之后需要重新分配超参数

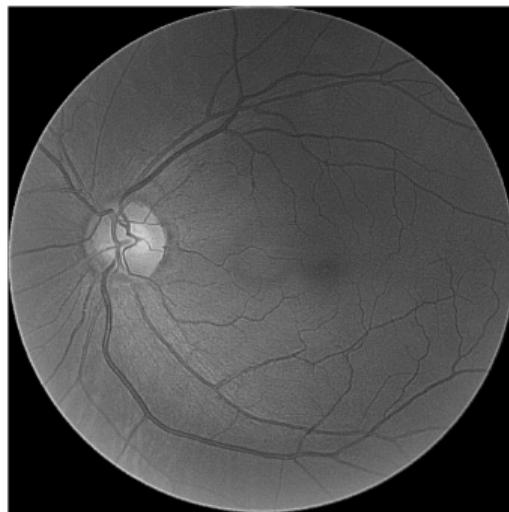
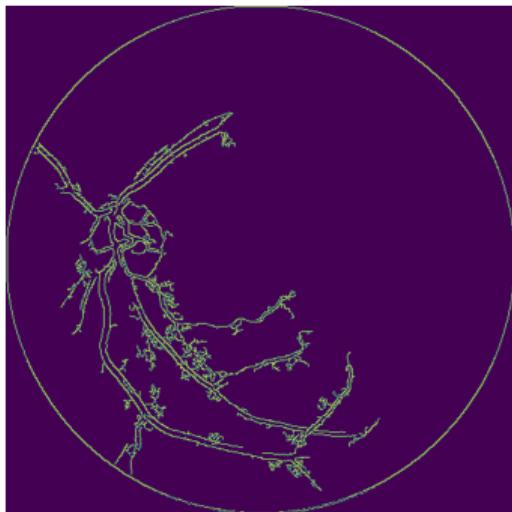
数据预处理

示例：原图 / 左右翻转 + 90 度逆时针旋转



数据预处理

示例: canny 处理 / 锐化



网络选择与搭建

TestNet/SResNet



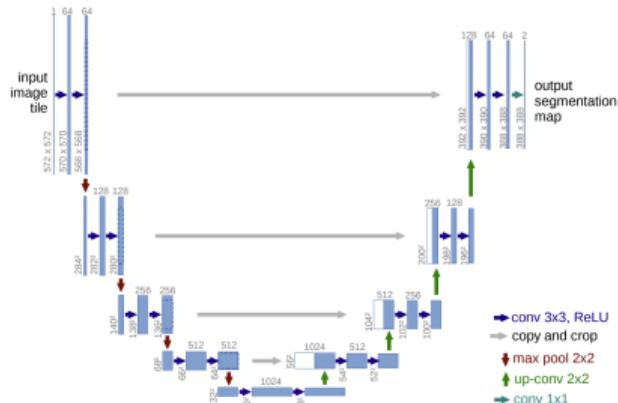
TestNet 和 SResNet 是本小组构建的两个结构简单的神经网络模型。

- TestNet: 卷积层 $\times 4$ + 全连接层 $\times 2$
- SResNet: 残差块 $\times 8$ + 全连接层 $\times 2$

网络选择与搭建

UNet

UNet 属于 FNC 的一种变体，其初衷是为解决生物医学影像方面的问题，效果也很好。UNet 主要用于图像分割。



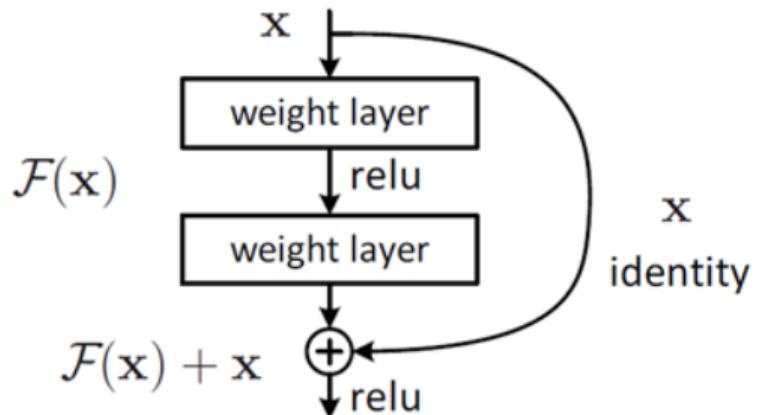
图：UNet 网络结构

网络选择与搭建

ResNet



解决梯度消失问题。残差单元将经过若干卷积层的输出与其原始输出相加得到的新结果作为下层网络的输入。

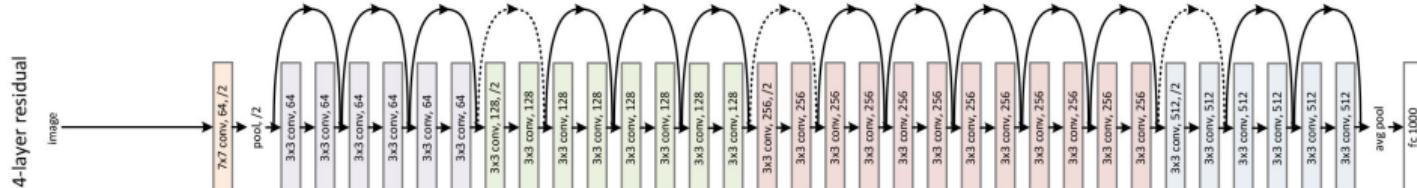


图：残差模块

网络选择与搭建

ResNet

经典 ResNet 网络分为 18 层、34 层、50 层、101 层、152 层共五个版本。主体部分每两个卷积层之间有一个短路连接，即一个残差单元。

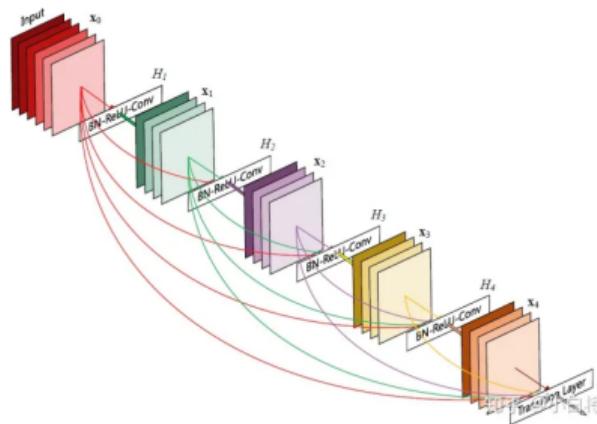


图：ResNet-34 网络结构

网络选择与搭建

DenseNet

相比于 ResNet，DenseNet 使用密集连接机制。其主要构建模块为稠密块和过渡层，前者定义输入和输出的连结方式，后者用来控制通道数使之不过大。



图：DenseNet 网络结构

数据迁移与微调



- **迁移学习**: 迁移学习是指通过将一个任务上学到的知识应用到另一个相关的任务中。在深度学习中，通常是通过在一个大规模数据集上训练的预训练模型，将其权重作为初始权重，然后将这个模型应用于目标任务。迁移学习的目的是利用源任务上学到的知识来提升目标任务的性能，特别是在目标任务的数据集相对较小或者标注不充分时。迁移学习的方式包括特征提取和微调。
- **微调**: 微调是迁移学习中的一种策略，指的是在一个预训练模型的基础上，通过进一步在目标任务的数据集上进行训练，调整模型的权重以适应目标任务。微调的典型场景是将预训练模型的最后几层或全连接层替换成新的层，然后在目标任务上进行训练。这使得模型能够学习适应目标任务的特定特征。

第 4 节

实验结果与分析



模型结果对比



- 未进行迁移学习时，SResNet 与 DenseNet 的结果较好
- 迁移学习后，ResNet 和 DenseNet 均取得不错的结果
- 数据增强和迁移学习对结果有较大提升

| 网络架构 | 无/有数据增强 | 无/有迁移学习 |
|----------|---------------|-----------------------|
| UNet | —/0.4821 | — |
| SResNet | 0.4908/0.5412 | — |
| ResNet | 0.4395/0.4795 | 0.4795/ 0.5950 |
| DenseNet | 0.5405/0.55 | 0.55/ 0.5964 |

表: Test Score 结果汇总

网络横向对比



- AUNet：效果最差，出乎意料
- SResNet：小数据集效果很好，大数据集预训练则优势不复存在
- DenseNet 效果好于 ResNet

网络纵向对比

迁移学习的效果

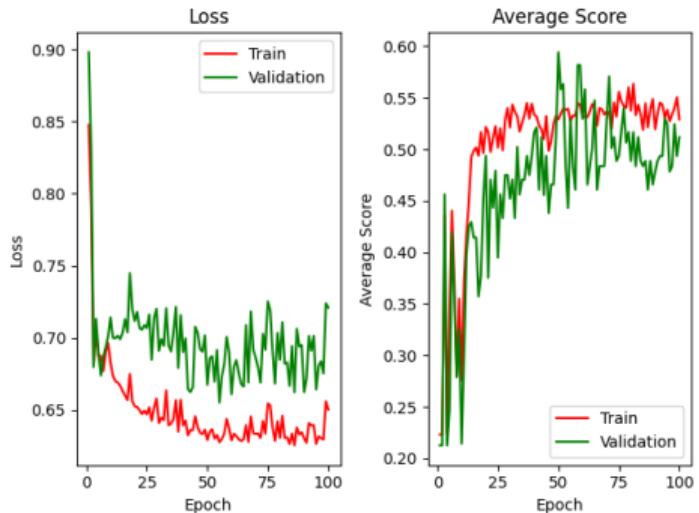


图: DenseNet 在应用迁移学习前的表现

网络纵向对比

迁移学习的效果

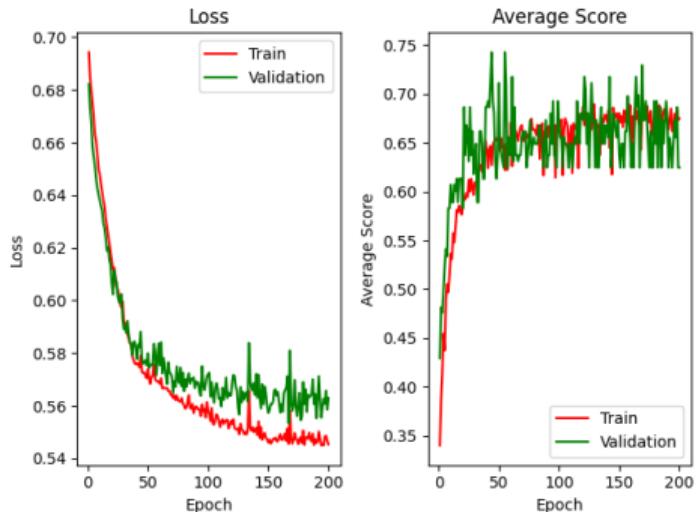


图: DenseNet 在应用迁移学习后的表现

实验历程

训练时的经验

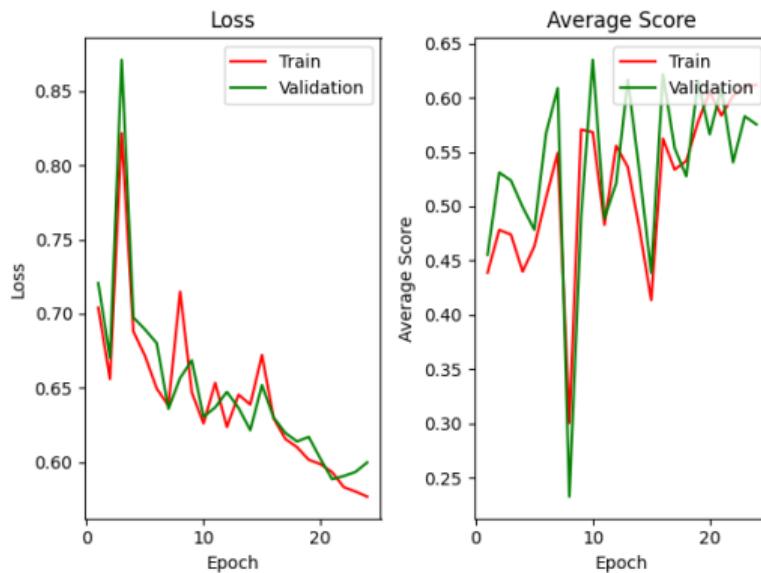


- ① 验证集的 loss 一直波动而没有明显的下降，而训练集 loss 有明显的下降，可能出现过拟合，需要进行数据增强，也可以调低模型复杂度，减少模型参数
- ② 验证集的 loss 波动较大，可能是验证集较小的原因，增大验证集能在一定程度上避免验证集的波动问题
- ③ 训练时，使用可变学习率能使得模型更加快速精准地逼近最优解
- ④ 观察 loss 曲线和 score 曲线，选取二者相近且分数都很高的轮次作为最终模型

实验历程

训练时的经验

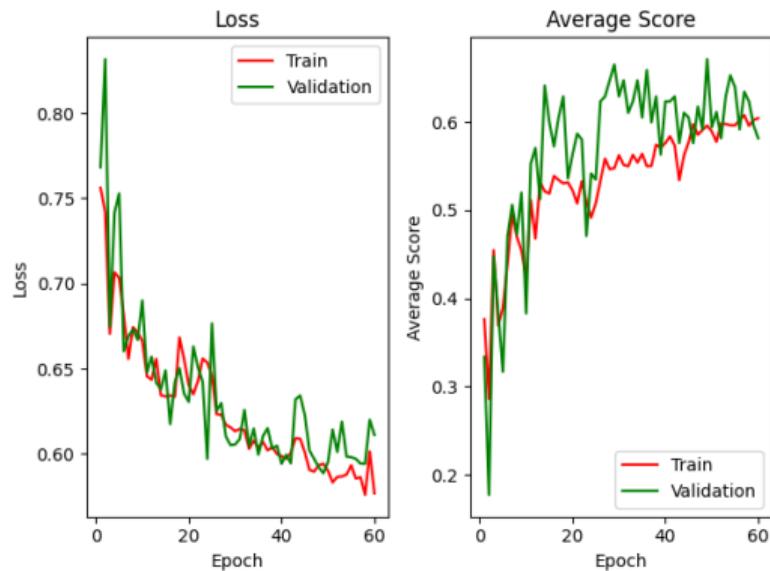
虽然能达到较高的峰值，但起伏太大，泛化性不强。



实验历程

训练时的经验

稳定在较高水平，结果更好。



第 5 节

特色与创新



数据增强与预处理



本项目数据集较小，仅有 712 张图片，而数据增强能一定程度弥补数据集较小的不足，提高模型的泛化能力，减少过拟合。此外，一些好的预处理方法也可以提高模型的分类效果。以下是我们尝试过的方法：

- 随机变换：图片以 0.25 的几率水平翻转，0.25 的几率垂直翻转，0.5 的几率不翻转，0.25 的几率进行 0 度、90 度、180 度、270 度旋转
- 高斯模糊：使用大小为 5*5 的核进行高斯模糊
- canny 算子：使用 canny 算子进行边缘检测
- 锐化操作：通过拉普拉斯算子进行图片锐化，提取图片的梯度信息
- 减法归一化： $Image = Image * \alpha + Image_{gaussian} * \beta + \gamma$

迁移学习



迁移学习主要是进行模型的预训练和微调。

- 使用在 ImageNet 数据集上训练好的模型参数，在此基础上应用于本项目的数据集，进行训练
- 模型的分类器（通常是最后的全连接层）需要修改
- 预训练模型起始的一些层，通常用于检测曲线、边缘这种特征，可以进行冻结，只训练模型的后半部分



项目分工

- 张昊然：负责代码部分，完成 SResNet/UNet，训练模型
- 张天瑞：负责 PPT 和 pre 部分，完成 DenseNet，训练模型
- 王瑶瑶：负责论文部分，完成 ResNet，训练模型

谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

